Zadanie rekrutacyjne

Data Solutions Engineer

Poniżej znajduje się przykładowe zadanie, z jakim będziesz mógł się spotkać na co dzień w pracy na stanowisku Data Solutions Engineer.

1. Wprowadzenie

Cloud Technologies zajmuje się przetwarzaniem bardzo dużych zbiorów danych pochodzących z ruchu w sieci. Jedną z podstawowych informacji, które otrzymujemy, jest adres URL. Na podstawie jego zawartości staramy się sklasyfikować zdarzenie do pewnej kategorii. Na przykład z poniższego adresu URL:

```
https://www.forbes.com/sites/billybambrough/2022/04/25/cryptocodex-coinbase-ceo-reveals-surprise-crypto-prediction-as-the-price-of-bitcoin-ethereum-bnb-xrp-solana-cardano-and-luna-crash
```

możemy wyciągnąć wiele informacji o potencjalnym zainteresowaniu kryptowalutami. Takich zdarzeń śledzimy setki tysięcy w każdej sekundzie, dlatego bardzo istotne jest efektywne wyszukiwanie w nich najpotrzebniejszych informacji. W tym celu posiadamy narzędzie do definiowania specjalnych keywordów, które w każdym URL-u szuka ich wystąpień.

Narzędzie to wymaga przygotowania danych wejściowych w formacie JSON. Przykładem takiego zapytania jest następujący JSON:

```
{"required":[{"keyword":"audi","mode":"m"}],"optional":[{"keyword":"a4","mode":"m"},{"keyword":"a3","mode":"m"}],"optionalThreshold":1}
```

2. Zasady tworzenia zapytania

Tryby dopasowania

1. **Tryb "m" (match) —** zlicza wystąpienie tylko wtedy, gdy keyword pojawia się w URL-u samodzielnie — oddzielony znakami niealfanumerycznymi, np. [...]-price-of-audi-a3-[...]. Nie zliczy dopasowania, jeśli słowo jest częścią innej frazy alfanumerycznej.

2. **Tryb "c" (contains) —** zlicza każde wystąpienie keywordu w URL-u, nawet jako fragment innego słowa, np. [...]-audition-[...] (co NIE zostałoby dopasowane w trybie "m").

Struktura zapytania

3. **required —** lista keywordów, które muszą wystąpić w URL-u jednocześnie.

4. **optional + optionalThreshold** — lista keywordów opcjonalnych oraz liczba określająca, ile z nich musi wystąpić w URL-u.

5. **Znak specjalny "-"** — dopasowuje dowolny znak niealfanumeryczny — np. keyword "honda-civic" dopasuje honda%civic, honda-civic, honda/civic itp.

Przykłady

- Zapytanie z jednym keywordem wymaganym i dwoma opcjonalnymi (próg = 1) — szuka URL-i z "audi" oraz co najmniej jednym z "a3"/"a4":

```
{"required":[{"keyword":"audi","mode":"m"}],"optional":[{"keyword":"a4","mode":"m"},{"key
word":"a3","mode":"m"}],"optionalThreshold":1}
```

- Wiele keywordów wymaganych jednocześnie — zwróci tylko URL-e zawierające zarówno "batman", jak i "robin":

```
{"required":[{"keyword":"batman","mode":"m"},{"keyword":"robin","mode":"m"}]}
```

- Można podać tylko listę required lub tylko optional:

```
{"required":[{"keyword":"audi","mode":"m"}]}
```

3. Estymator zapytań

Każde z przygotowanych zapytań jest sprawdzane setki tysięcy razy na sekundę, dlatego zależy nam na tym, żeby na produkcję trafiały tylko dobrze przygotowane i dające trafne rezultaty zapytania. W tym celu zbudowaliśmy estymator, w którym można sprawdzić zapytanie przed jego ostatecznym wgraniem.

Na potrzeby tego zadania z estymatora można skorzystać, wywołując następującą komendę:

```
curl --data '@test.json' 'https://urlkeywords.ctpl.dev/keywordURLs'
```

Komenda zwraca w wyniku JSON z rezultatami dla zapytania znajdującego się w pliku test.json. Na podstawie odpowiedzi możemy sprawdzić, czy stworzone przez nas zapytanie zostało dopasowane do jakichś URL-i i czy zawierają one takie informacje, o jakie nam chodziło. Często zdarza się, że część rezultatów oznacza jednak coś innego niż chcieliśmy osiągnąć — takie zapytanie trzeba wtedy odpowiednio dopracować.

Porównanie: zapytanie zbyt szerokie vs. trafne

✗ **ZBYT SZEROKIE — dużo wyników, ale wiele niepoprawnie sklasyfikowanych**

```
{"required":[{"keyword":"audi","mode":"c"}]}
```

✓ **TRAFNE — precyzyjne dopasowanie dzięki dodatkowym słowom opcjonalnym**

```
{"required":[{"keyword":"audi","mode":"m"}],"optional":[{"keyword":"a4","mode":"m"},{"ke
yword":"a3","mode":"m"}],"optionalThreshold":1}
```


4. Zadanie

> **CEL ZADANIA**
> Stworzenie taksonomii marek różnych alkoholi, które będzie dało się rozpoznać w danych ruchu sieciowego.

W tym celu należy zacząć od przygotowania listy alkoholi. Przykładowy fragment listy może wyglądać na przykład tak:

- [...]
- 11. Bacardi
- 12. Martini
- 13. Bombay Sapphire
- 14. Eristoff
- 15. Grey Goose
- [...]

Kolejnym krokiem jest przygotowanie odpowiednich zapytań i sprawdzenie ich w estymatorze. W rezultacie chcielibyśmy dostać możliwie najdłuższą listę odnalezionych alkoholi wraz z definicjami zapytań, które będą w stanie przypisać URL-e do danej pozycji. W liście powinny pojawić się tylko pozycje, które złapały przynajmniej jeden dobry URL.

Format wyniku

Zwrócony wynik powinien mieć postać pliku JSON o nazwie **`imienazwisko.json`** (np. dla Jana Kowalskiego: **`jkowalski.json`**) z listą zapytań, w których dodane jest dodatkowe pole **`"id"`** z nazwą danego alkoholu, np.:


```
{"results":[  {"id":"slabe_audi","required":[{"keyword":"audi","mode":"c"}]},
{"id":"dobre_audi","required":[{"keyword":"audi","mode":"m"}],"optional":[{"keyword":"a4"
,"mode":"m"},{"keyword":"a3","mode":"m"}],"optionalThreshold":1}]}
```


Prosimy też o przesłanie komentarza z opisem podejścia i sposobu rozwiązania.

5. Wskazówki

📋 Lista alkoholi i jej długość jest dowolna — znalezienie i przygotowanie jej jest elementem zadania.

⚠️ Zwróć uwagę, żeby w rezultacie nie przekazać pozycji z alkoholami, które w ogóle nie zostaną dopasowane przez estymator.

🎯 Ważne jest, żeby wszystkie złapane przez estymator URL-e były trafne i klasyfikowały dokładnie tę rzecz, której oczekujemy.

⚙️ Ręczna praca może dać bardzo dobre rezultaty, ale cenimy automatyzację i sprytne rozwiązania.

KONTAKT

W razie pytań lub wystąpienia problemów technicznych prosimy kontaktować się z: franciszek.grodowski@onaudience.com